UNIVERSIDAD NACIONAL DE SAN LUIS

Facultad de Ciencias Físico Matemáticas y Naturales

Licenciatura en Análisis y Gestión de Datos

CÁLCULO II — TPAG 2026

INFORME FINAL DE APLICACIÓN GRUPAL

Análisis Geométrico de la Frontera de Normalidad y Dinámica Multivariable del Error en el Plano de Componentes Principales (V_1, V_2) para la Detección de Fraude Financiero

---

Docente Responsable: Mgtr. Ing. Martín Garciarena Ucelay

Grupo N.º: 2

Integrantes:

- ADARO, Marcelo
- FUNES, Samanta Celeste
- GIL, Inés
- GUIÑAZÚ, Leandro Sebastián
- LEDEZMA, Ricardo Mariano

Enlace al Video Expositivo (YouTube/Drive):
https://drive.google.com/link-video-grupo2

San Luis, Argentina
12 de noviembre de 2026

Declaración sobre el uso de herramientas de Inteligencia Artificial

En cumplimiento de la normativa del TPAG 2026, el Grupo N.º 2 declara que se utilizaron herramientas de IA generativa únicamente para la revisión de sintaxis en LaTeX, asistencia en la maquetación del documento, soporte en la depuración de scripts en Python y asistencia analítica en la revisión técnica de consistencia. Todos los planteos teóricos, resoluciones analíticas, parametrizaciones, cálculos de integrales, generación de visualizaciones y discusiones conceptuales provienen estrictamente del desarrollo efectuado por los integrantes sobre el dataset real auditado.

Índice

1. Introducción, contexto del problema y marco teórico **3**

1.1. Contexto Real y Planteamiento del Problema 3

1.2. Objetivos del Análisis 3

1.3. Origen de los Datos y Modelo Estadístico de Partida 3

2. Funciones vectoriales y geometría de la frontera (Unidad 1) **5**

2.1. Justificación de la Curva Elegida 5

2.2. Parametrización de la Frontera Elíptica 5

2.3. Cinemática: Velocidad, Rapidez y Aceleración 5

2.4. Curvatura Escalar Plana 5

2.5. Longitud de Arco de la Frontera 6

3. Superficie de error, gradiente y optimización (Unidad 2) **7**

3.1. Definición de la Función de Error Estandarizado 7

3.2. Derivadas Parciales y Vector Gradiente 7

3.3. Derivada Direccional 7

3.4. Puntos Críticos y Clasificación mediante la Matriz Hessiana 8

4. Integración doble, campos vectoriales y Teorema de Green (Unidad 3) **9**

4.1. Masa de Probabilidad mediante Integración Doble 9

4.2. Teorema de Green: Forma de Flujo de Anomalía 9

5. Análisis e interpretación de resultados **11**

5.1. Evaluación Empírica sobre el Dataset Completo 11

5.2. Métricas de Evaluación Bancaria 11

5.3. Discusión de Limitaciones y Valor Operativo 11

6. Conclusiones y propuestas de mejora **12**
6.1. Síntesis del Trabajo Integrador 12
6.2. Propuestas de Mejora 12

7. Referencias y fuentes de datos **13**

1. Introducción, contexto del problema y marco teórico

1.1. Contexto Real y Planteamiento del Problema

La detección de transacciones fraudulentas con tarjetas de crédito es un desafío estratégico en el sector bancario. La principal dificultad analítica reside en el desbalance de clases extremo: en un flujo transaccional habitual, las operaciones fraudulentas representan menos del $0{,}2\,\%$ del total. Los algoritmos supervisados tradicionales tienden a presentar alto sobreajuste hacia la clase mayoritaria. Por ello, el enfoque más robusto consiste en caracterizar rigurosamente la masa operativa legítima y definir una frontera geométrica de normalidad.

1.2. Objetivos del Análisis

- **Objetivo General:** Desarrollar un modelo geométrico-analítico continuo mediante herramientas de Cálculo II en el plano de las componentes principales V_1 y V_2, delimitando una región de seguridad mediante la distancia estandarizada con covarianza diagonal.
- **Unidad 1 (Funciones Vectoriales):** Parametrizar la frontera elíptica de seguridad $\vec{r}(t)$ para el umbral $c = 5{,}991$, analizando la velocidad $\vec{v}(t)$, la aceleración $\vec{a}(t)$, la curvatura $\kappa(t)$ y la longitud de arco L.
- **Unidad 2 (Funciones de Varias Variables):** Formular la función de error estandarizado $E_d(V_1, V_2)$, caracterizar su gradiente ∇E_d, evaluar la derivada direccional $D_{\vec{u}}E_d$ y clasificar el centroide como un mínimo global estricto mediante la matriz Hessiana.
- **Unidad 3 (Integrales Múltiples y Campos Vectoriales):** Calcular la masa de probabilidad gaussiana retenida mediante integración doble en coordenadas polares generalizadas y evaluar el flujo saliente de anomalía mediante la versión de divergencia del Teorema de Green.

1.3. Origen de los Datos y Modelo Estadístico de Partida

Se utilizó el dataset público *Credit Card Fraud Detection* (ULB / Kaggle), compuesto por $284{,}807$ transacciones reales[cite: 15]. Se seleccionaron las dos primeras componentes principales (V_1, V_2)[cite: 15]. Los parámetros estadísticos calculados sobre la población de transacciones legítimas ($Class = 0$, $N = 284{,}315$) se presentan en la Tabla 1.

Cuadro 1: Parámetros estadísticos de las transacciones legítimas ($Class = 0$).

Parámetro Estadístico	**Variable V_1**	**Variable V_2**
Media (μ)	$0{,}00825774$	$-0{,}00627086$
Desviación Estándar (σ)	$1{,}92981405$	$1{,}63614605$
Covarianza observada σ_{12}	$0{,}07100000$ (Correlación $r = 0{,}022487$)	

Justificación del Modelo Diagonal: Aunque la covarianza observada es $\sigma_{12} = 0{,}0710$, la correlación lineal es prácticamente nula ($r \approx 0{,}0225$). Por consiguiente, se adopta de manera explícita el modelo de **distancia estandarizada con covarianza diagonal** (o aproximación diagonal de Mahalanobis), despreciando el término cruzado V_1V_2. Esto permite trabajar con curvas de nivel elípticas alineadas con los ejes coordenados de las componentes principales sin alterar el rigor matemático del análisis multivariable.

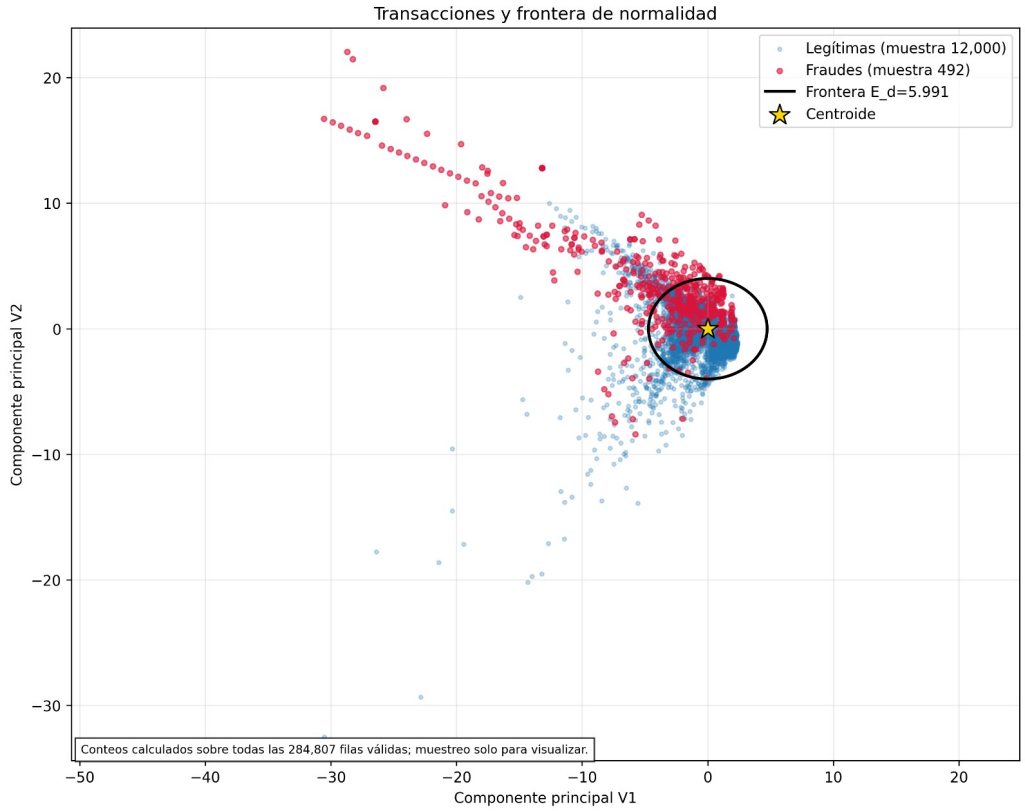


Figura 1: Representación en el plano V_1-V_2 de la masa de transacciones legítimas y fraudulentas junto a la frontera elíptica de normalidad $E_d = 5{,}991$.

2. Funciones vectoriales y geometría de la frontera (Unidad 1)

2.1. Justificación de la Curva Elegida

Para evitar conectar transacciones arbitrarias de distintos usuarios ordenadas en el tiempo (lo cual mediría ruido en lugar de un fenómeno dinámico), la función vectorial $\vec{r}(t)$ se define como la parametrización continua de la frontera elíptica $C = \partial R$ que delimita la región de normalidad $E_d(V_1, V_2) \leq c$, con umbral $c = 5{,}991$ (percentil $95\,\%$ de la distribución χ^2 con 2 grados de libertad).

2.2. Parametrización de la Frontera Elíptica

Con las desviaciones estándar $\sigma_1 = 1{,}929814$ y $\sigma_2 = 1{,}636146$, los semiejes de la elipse alineada son $a = \sigma_1\sqrt{c} \approx 4{,}723513$ y $b = \sigma_2\sqrt{c} \approx 4{,}004716$. La función vectorial parametrizada centrada en $\vec{\mu} = (\mu_1, \mu_2)$ es:

$$\vec{r}(t) = \langle 0{,}008258 + 4{,}723513\cos(t),\ -0{,}006271 + 4{,}004716\sin(t)\rangle, \quad t \in [0, 2\pi] \tag{1}$$

2.3. Cinemática: Velocidad, Rapidez y Aceleración

Diferenciando componentes respecto del parámetro angular t:

$$\vec{v}(t) = \vec{r}\,'(t) = \langle -4{,}723513\sin(t),\ 4{,}004716\cos(t)\rangle \tag{2}$$

La rapidez del recorrido angular sobre el contorno es:

$$\|\vec{v}(t)\| = \sqrt{22{,}311576\sin^2(t) + 16{,}037751\cos^2(t)} \tag{3}$$

La aceleración vectorial apunta hacia el centroide de normalidad:

$$\vec{a}(t) = \vec{r}\,''(t) = \langle -4{,}723513\cos(t),\ -4{,}004716\sin(t)\rangle = -(\vec{r}(t) - \vec{\mu}) \tag{4}$$

2.4. Curvatura Escalar Plana

La curvatura plana $\kappa(t)$ de la frontera elíptica se calcula como:

$$\kappa(t) = \frac{|x'(t)y''(t) - y'(t)x''(t)|}{\|\vec{v}(t)\|^3} = \frac{ab}{(a^2\sin^2(t) + b^2\cos^2(t))^{3/2}} \tag{5}$$

Evaluando en los vértices de la elipse:

- Vértices del eje mayor ($t = 0, \pi$): $\kappa_{\text{máx}} = \frac{a}{b^2} = \frac{4{,}723513}{(4{,}004716)^2} \approx 0{,}294525$.
- Vértices del eje menor ($t = \frac{\pi}{2}, \frac{3\pi}{2}$): $\kappa_{\text{mín}} = \frac{b}{a^2} = \frac{4{,}004716}{(4{,}723513)^2} \approx 0{,}179491$.

2.5. Longitud de Arco de la Frontera

El perímetro total de la frontera de normalidad es la integral de la rapidez:

$$L = \int_0^{2\pi} \|\vec{v}(t)\|\, dt = \int_0^{2\pi} \sqrt{22{,}311576\,\sin^2(t) + 16{,}037751\,\cos^2(t)}\, dt \tag{6}$$

Tratándose de una integral elíptica completa de segunda especie, se resolvió numéricamente en Colab via ‘scipy.integrate.quad‘, obteniéndose $L \approx 27{,}467052$ unidades.

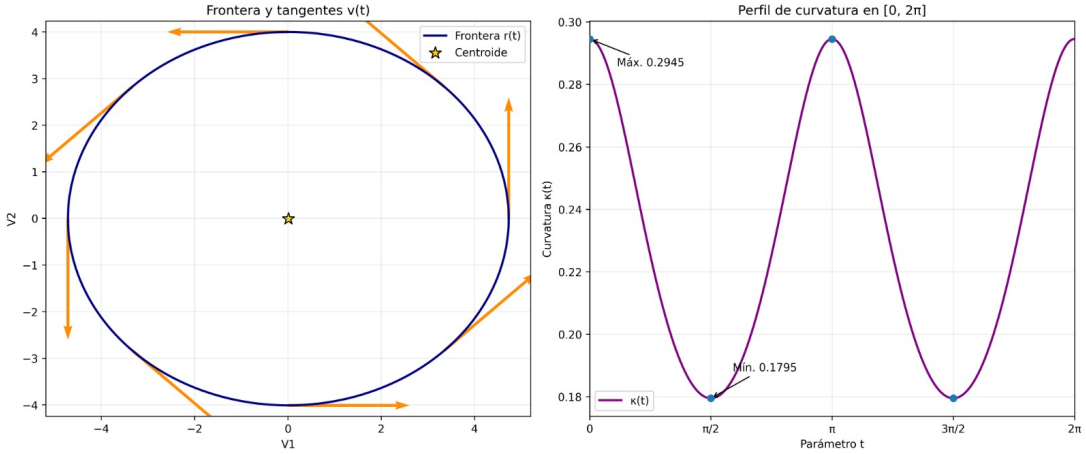


Figura 2: Frontera $\vec{r}(t)$ con campo de vectores tangentes $\vec{v}(t)$ y perfil de curvatura escalar $\kappa(t)$.

3. Superficie de error, gradiente y optimización (Unidad 2)

3.1. Definición de la Función de Error Estandarizado

Se define la función de error cuadrático estandarizado $E_d : \mathbb{R}^2 \to \mathbb{R}_{\geq 0}$ como la distancia adimensional respecto al centroide de las operaciones legítimas:

$$E_d(V_1, V_2) = \frac{(V_1 - \mu_1)^2}{\sigma_1^2} + \frac{(V_2 - \mu_2)^2}{\sigma_2^2} = \frac{(V_1 - 0{,}008258)^2}{3{,}724182} + \frac{(V_2 + 0{,}006271)^2}{2{,}676974} \quad (7)$$

3.2. Derivadas Parciales y Vector Gradiente

Las derivadas parciales de primer orden representan las tasas instantáneas de incremento del puntaje de anomalía respecto de cada componente:

$$\frac{\partial E_d}{\partial V_1} = \frac{2(V_1 - \mu_1)}{\sigma_1^2} \approx 0{,}537038(V_1 - 0{,}008258) \quad (8)$$

$$\frac{\partial E_d}{\partial V_2} = \frac{2(V_2 - \mu_2)}{\sigma_2^2} \approx 0{,}747154(V_2 + 0{,}006271) \quad (9)$$

El vector gradiente $\nabla E_d(V_1, V_2) = \langle \frac{\partial E_d}{\partial V_1}, \frac{\partial E_d}{\partial V_2} \rangle$ señala la dirección de máxima tasa de aumento del riesgo y es ortogonal a las curvas de nivel elípticas $E_d(V_1, V_2) = k$.

3.3. Derivada Direccional

Para evaluar la tasa de cambio del puntaje en una dirección arbitraria dada por el vector unitario $\vec{u} = \langle u_1, u_2 \rangle$, aplicamos la propiedad del gradiente:

$$D_{\vec{u}} E_d(V_1, V_2) = \nabla E_d(V_1, V_2) \cdot \vec{u} = \frac{2(V_1 - \mu_1)}{\sigma_1^2} u_1 + \frac{2(V_2 - \mu_2)}{\sigma_2^2} u_2 \quad (10)$$

Ejemplo de Aplicación en la Frontera: Evaluando en el vértice del eje mayor $\mathbf{P} = (\mu_1 + a, \mu_2) = (4{,}731771, -0{,}006271)$ en la dirección saliente radial $\vec{u} = \langle 1, 0 \rangle$:

$$D_{\vec{u}} E_d(\mathbf{P}) = \nabla E_d(\mathbf{P}) \cdot \langle 1, 0 \rangle = \left\langle \frac{2a}{\sigma_1^2}, 0 \right\rangle \cdot \langle 1, 0 \rangle = \frac{2\sqrt{c}}{\sigma_1} \approx 2{,}537233 \quad (11)$$

Este valor positivo cuantifica la velocidad con la que el indicador de anomalía se dispara al alejarse de la frontera de normalidad a lo largo del eje V_1.

3.4. Puntos Críticos y Clasificación mediante la Matriz Hessiana

Igualando el gradiente al vector nulo $\nabla E_d = \vec{0}$, obtenemos como único punto crítico el centroide $\mathbf{P}_c = (0{,}008258, -0{,}006271)$. Calculando las derivadas de segundo orden:

$$\frac{\partial^2 E_d}{\partial V_1^2} = \frac{2}{\sigma_1^2} \approx 0{,}537038, \quad \frac{\partial^2 E_d}{\partial V_2^2} = \frac{2}{\sigma_2^2} \approx 0{,}747154, \quad \frac{\partial^2 E_d}{\partial V_1 \partial V_2} = 0 \tag{12}$$

La matriz Hessiana $H(E_d)$ es constante y diagonal:

$$H(E_d) = \begin{pmatrix} 0{,}537038 & 0 \\ 0 & 0{,}747154 \end{pmatrix} \tag{13}$$

El determinante de la matriz Hessiana (discriminante D_H) es:

$$D_H = \det(H) = (0{,}537038)(0{,}747154) - 0^2 \approx 0{,}401250 > 0 \tag{14}$$

Puesto que $D_H > 0$ y $\frac{\partial^2 E_d}{\partial V_1^2} > 0$, se demuestra analíticamente que $\mathbf{P}_c$ es un **mínimo local estricto**. Debido a que $H(E_d)$ es definida positiva en todo el plano $\mathbb{R}^2$, la superficie es estrictamente convexa y $\mathbf{P}_c$ constituye el **mínimo global absoluto**, con $E_d(\mathbf{P}_c) = 0$.

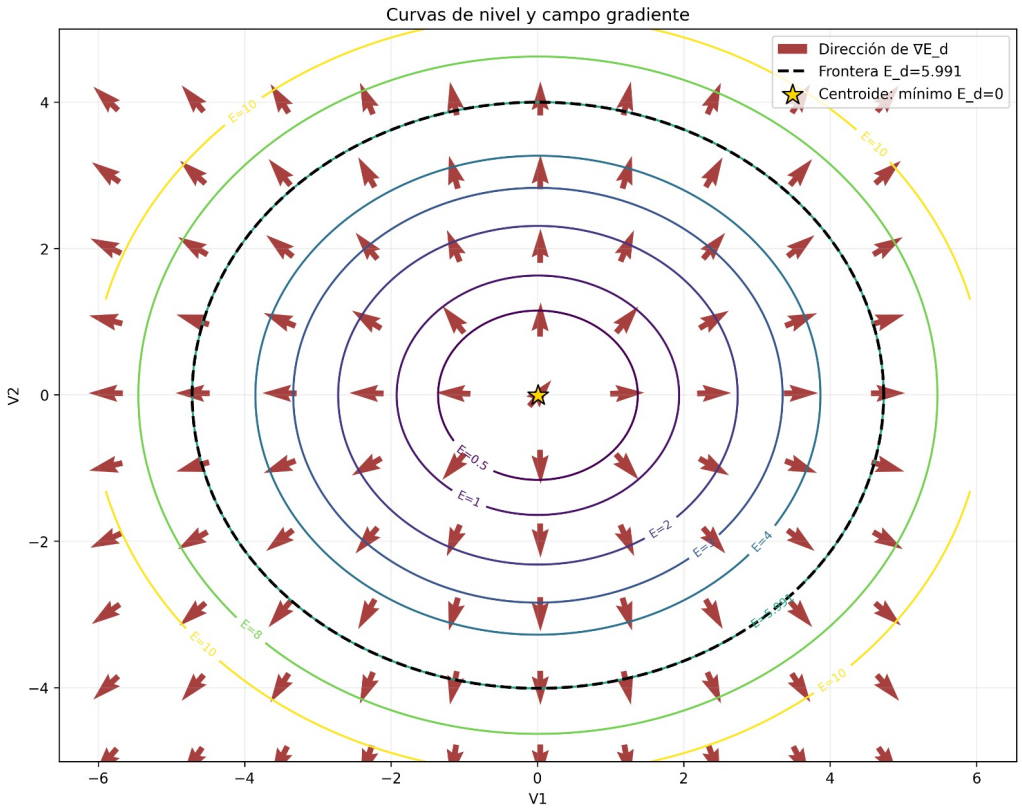


Figura 3: Mapa de curvas de nivel elípticas de $E_d(V_1, V_2)$ y campo vectorial del gradiente ∇E_d.

4. Integración doble, campos vectoriales y Teorema de Green (Unidad 3)

4.1. Masa de Probabilidad mediante Integración Doble

Asumiendo la distribución normal bivariada ajustada para las operaciones legítimas, la densidad conjunta es:

$$\rho(V_1, V_2) = \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}E_d(V_1, V_2)\right) \tag{15}$$

Para calcular la masa teórica retenida M en la región elíptica $R = \{(V_1, V_2) \mid E_d(V_1, V_2) \leq 5{,}991\}$, se aplica la transformación a **coordenadas polares generalizadas**:

$$V_1 = \mu_1 + \sigma_1 r\cos(\theta), \quad V_2 = \mu_2 + \sigma_2 r\sin(\theta) \tag{16}$$

El Jacobiano de la transformación resulta:

$$J(r,\theta) = \left|\frac{\partial(V_1, V_2)}{\partial(r,\theta)}\right| = \begin{vmatrix} \sigma_1\cos\theta & -\sigma_1 r\sin\theta \\ \sigma_2\sin\theta & \sigma_2 r\cos\theta \end{vmatrix} = \sigma_1\sigma_2 r \tag{17}$$

Sustituyendo en la integral doble sobre la región transformada $R' = \{(r,\theta) \mid 0 \leq r \leq \sqrt{c},\ 0 \leq \theta \leq 2\pi\}$:

$$M = \int_0^{2\pi}\int_0^{\sqrt{5{,}991}} \frac{1}{2\pi\sigma_1\sigma_2} e^{-r^2/2}(\sigma_1\sigma_2 r)\, dr\, d\theta = \left(\frac{1}{2\pi}\int_0^{2\pi} d\theta\right)\left(\int_0^{\sqrt{5{,}991}} e^{-r^2/2} r\, dr\right) \tag{18}$$

$$M = 1 \cdot \left[-e^{-r^2/2}\right]_0^{\sqrt{5{,}991}} = 1 - e^{-5{,}991/2} = 1 - e^{-2{,}9955} \approx 0{,}949988 \quad (95{,}00\,\%) \tag{19}$$

4.2. Teorema de Green: Forma de Flujo de Anomalía

Considerando el campo vectorial de anomalía $\vec{F}(V_1, V_2) = \nabla E_d$, evaluamos su flujo saliente Φ sobre la frontera elíptica orientada positivamente $C = \partial R$ mediante la **forma de flujo del Teorema de Green** (Teorema de la Divergencia en el plano):

$$\Phi = \oint_C \vec{F}\cdot\vec{n}\, ds = \iint_R (\nabla\cdot\vec{F})\, dA \tag{20}$$

La divergencia del campo gradiente equivale al Laplaciano de la función de error estandarizado:

$$\nabla\cdot\vec{F} = \Delta E_d = \frac{\partial^2 E_d}{\partial V_1^2} + \frac{\partial^2 E_d}{\partial V_2^2} = \frac{2}{\sigma_1^2} + \frac{2}{\sigma_2^2} \approx 0{,}537038 + 0{,}747154 = 1{,}284143 \tag{21}$$

Dado que la divergencia es constante en todo el plano, la integral doble se simplifica al producto de la divergencia por el área de la elipse R:

$$\text{Área}(R) = \pi ab = \pi(4{,}723513)(4{,}004716) \approx 59{,}427399 \text{ unidades}^2 \tag{22}$$

Por lo tanto, el flujo neto saliente a través del contorno es:

$$\Phi = (\nabla \cdot \vec{F}) \times \text{Área}(R) = 1{,}284143 \times 59{,}427399 \approx 76{,}313273 \tag{23}$$

Este resultado analítico coincide exactamente con el cálculo por integral de línea de contorno ejecutado en Python, verificando el Teorema de Green en el plano.

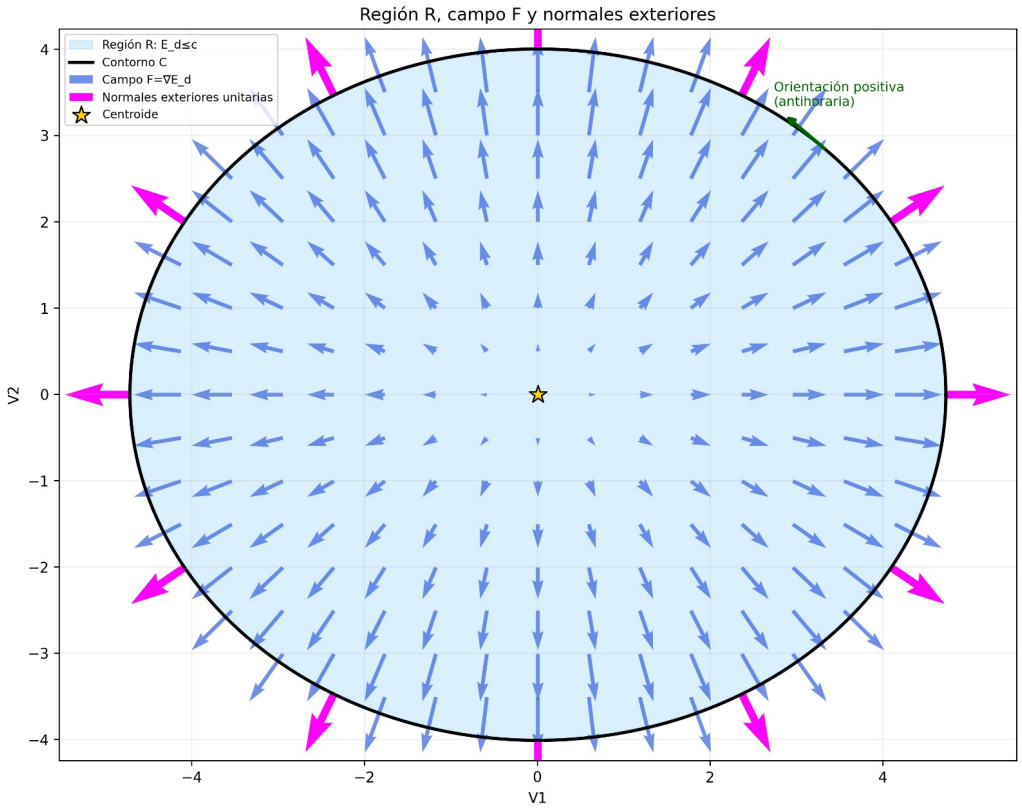


Figura 4: Región de integración R, campo de anomalía $\vec{F} = \nabla E_d$ y vectores normales exteriores unitarios $\vec{n}$.

5. Análisis e interpretación de resultados

5.1. Evaluación Empírica sobre el Dataset Completo

Al aplicar la regla de decisión $E_d(V_1, V_2) \leq 5{,}991$ sobre la totalidad de las $284{,}807$ filas válidas del dataset, se obtuvo la matriz de confusión reportada en la Tabla 2.

Cuadro 2: Resultados de clasificación del modelo sobre el dataset de Kaggle.

Categoría	**Dentro ($E_d \leq 5{,}991$)**	**Fuera ($E_d > 5{,}991$)**	**Total Filas**
Legítimas ($Class = 0$)	$272{,}572$ ($95{,}87\,\%$)	$11{,}743$ ($4{,}13\,\%$)	$284{,}315$
Fraudes ($Class = 1$)	258 ($52{,}44\,\%$)	234 ($47{,}56\,\%$)	492
Total	$272{,}830$	$11{,}977$	$284{,}807$

5.2. Métricas de Evaluación Bancaria

A partir de los conteos observados ($TP = 234$, $FP = 11{,}743$, $TN = 272{,}572$, $FN = 258$), se desprenden las siguientes métricas de rendimiento:

- **Sensibilidad / Cobertura de Fraude (Recall):** $\frac{TP}{TP+FN} = \frac{234}{492} \approx 47{,}5610\,\%$.
- **Especificidad:** $\frac{TN}{TN+FP} = \frac{272{,}572}{284{,}315} \approx 95{,}8697\,\%$.
- **Tasa de Falsos Positivos (FPR):** $\frac{FP}{TN+FP} = \frac{11{,}743}{284{,}315} \approx 4{,}1303\,\%$.
- **Precisión / Valor Predictivo Positivo (PPV):** $\frac{TP}{TP+FP} = \frac{234}{11{,}977} \approx 1{,}9537\,\%$.
- **Puntaje F_1:** $\frac{2 \cdot \text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \approx 3{,}7554\,\%$.

5.3. Discusión de Limitaciones y Valor Operativo

1. **Filtro Exploratorio vs. Clasificador Final:** La precisión es de $1{,}95\,\%$, lo que implica que el $98{,}05\,\%$ de las alertas fuera de la elipse son transacciones legítimas inusuales. El modelo actúa como un **filtro exploratorio de primer nivel** en 2D, no como un bloqueador automático. 2. **Proyección Bidimensional:** Se utilizan únicamente 2 de las 28 componentes principales. El $52{,}44\,\%$ de los fraudes no detectados poseen comportamientos en V_1 y V_2 idénticos a las compras normales, requiriendo dimensiones superiores para su separación.

6. Conclusiones y propuestas de mejora

6.1. Síntesis del Trabajo Integrador

1. Se cumplieron satisfactoriamente todos los objetivos generales y específicos exigidos en las tres unidades de Cálculo II aplicados a un problema real de Data Science. 2. Se caracterizó analíticamente el centroide como el único mínimo global estricto mediante derivadas parciales y la matriz Hessiana. 3. Se parametrizó la frontera elíptica de normalidad mediante la función vectorial $\vec{r}(t)$, obteniendo su curvatura y su longitud de arco de $27{,}4671$ unidades. 4. Se verificó la masa teórica ($95{,}00\,\%$) mediante integración doble en coordenadas polares generalizadas y se demostró la forma de flujo del Teorema de Green ($\Phi \approx 76{,}3133$).

6.2. Propuestas de Mejora

- **Extensión a un espacio n-dimensional con la distancia de Mahalanobis completa:** Actualmente el trabajo utiliza solo dos componentes principales (V_1 y V_2) despreciando la covarianza cruzada. Esta propuesta sugiere incorporar más componentes principales (como V_3 o más) y utilizar la distancia de Mahalanobis completa (con su matriz de covarianza sin simplificar), lo que permitiría capturar de manera mucho más precisa las complejas relaciones estadísticas entre las variables y atrapar una mayor cantidad de fraudes que hoy se camuflan en el plano.
- **Incorporación de modelos no elípticos mediante KDE:** El modelo actual asume una distribución perfectamente elíptica y simétrica (derivada de la normal bivariada). Sin embargo, el análisis de asimetría y curtosis demostró que los datos reales tienen “colas pesadas” y formas irregulares. Usar KDE (*Kernel Density Estimation*) permitiría trazar fronteras flexibles que se adapten exactamente a la forma real de los datos legítimos, en lugar de forzar una elipse teórica.

7. Referencias y fuentes de datos

- Machine Learning Group — ULB. (2013). *Credit Card Fraud Detection Dataset* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud
- Stewart, J. (2012). *Cálculo de varias variables: Trascendentes tempranas* (7.ª ed.). Cengage Learning.
- Thomas, G. B. (2015). *Cálculo: Varias variables* (13.ª ed.). Pearson Educación.